



Functional API: руководство

Функциональный API Keras — это способ создания сложных моделей, таких, например, которые имеют несколько выходов, модели с общими слоями, или ациклические графы.

В этом руководстве предполагается, что вы уже знакомы с моделью Sequential.

Давайте рассмотрим несколько простых примеров.

Первый пример: полносвязная сеть

Модель Sequential, вероятно, является лучшей реализацией подобной сети, но нам просто нужно начать с чего-то действительно простого.

- Экземпляр слоя применяется к тензору и возвращает тензор.
- Входной и выходной тензор(ы) затем могут также использоваться для определения модели
- Такая модель обучается также как и модель Sequential

```
from keras.layers import Input, Dense
```

```
from keras.models import Model
```

```
# Этот код вернет тензор
```

```
inputs = Input(shape=(784,))
```

```
# Экземпляр слоя применяется к тензору и возвращает новый тензор
```

```
output_1 = Dense(64, activation='relu')(inputs)
```

```
output_2 = Dense(64, activation='relu')(output_1)
```

```
predictions = Dense(10, activation='softmax')(output_2)
```

```
# Мы создали модель, включающую
```

```
# один входной слой и три Dense слоя
```

```
model = Model(inputs=inputs, outputs=predictions)
```

```
model.compile(optimizer='rmsprop',
```

```
    loss='categorical_crossentropy',
```

```
    metrics=['accuracy'])
```

```
model.fit(data, labels) # Старт обучения
```

Все модели могут вызываться как слои

С помощью функционального API вы можете легко использовать обученные модели: вы можете применять любую модель к тензору, как если бы она была слоем. Обратите внимание, что вызывая модель, вы не просто повторно используете ее архитектуру, но также повторно используете и ее веса.

```
x = Input(shape=(784,))
```

```
# Это сработает и вернет 10мерный-softmax вектор, который мы определили выше.
```

```
y = model(x)
```

Это может помочь, например, быстро создавать модели, способные обрабатывать последовательности входных данных. Вы можете превратить модель классификации изображений в модель классификации видео, изменив всего одну строку.

```
from keras.layers import TimeDistributed
```

```
# Входной тензор для последовательности из 20 кадров
```

```
# каждый из которых содержит 784-мерный вектор
```

```
input_sequences = Input(shape=(20, 784))
```

Применяем нашу предыдущую модель к каждому кадру во входной последовательности.

Выход предыдущей модели был 10-мерный softmax вектор

Поэтому на выходе новой модели будет последовательность из 20 10-мерных векторов

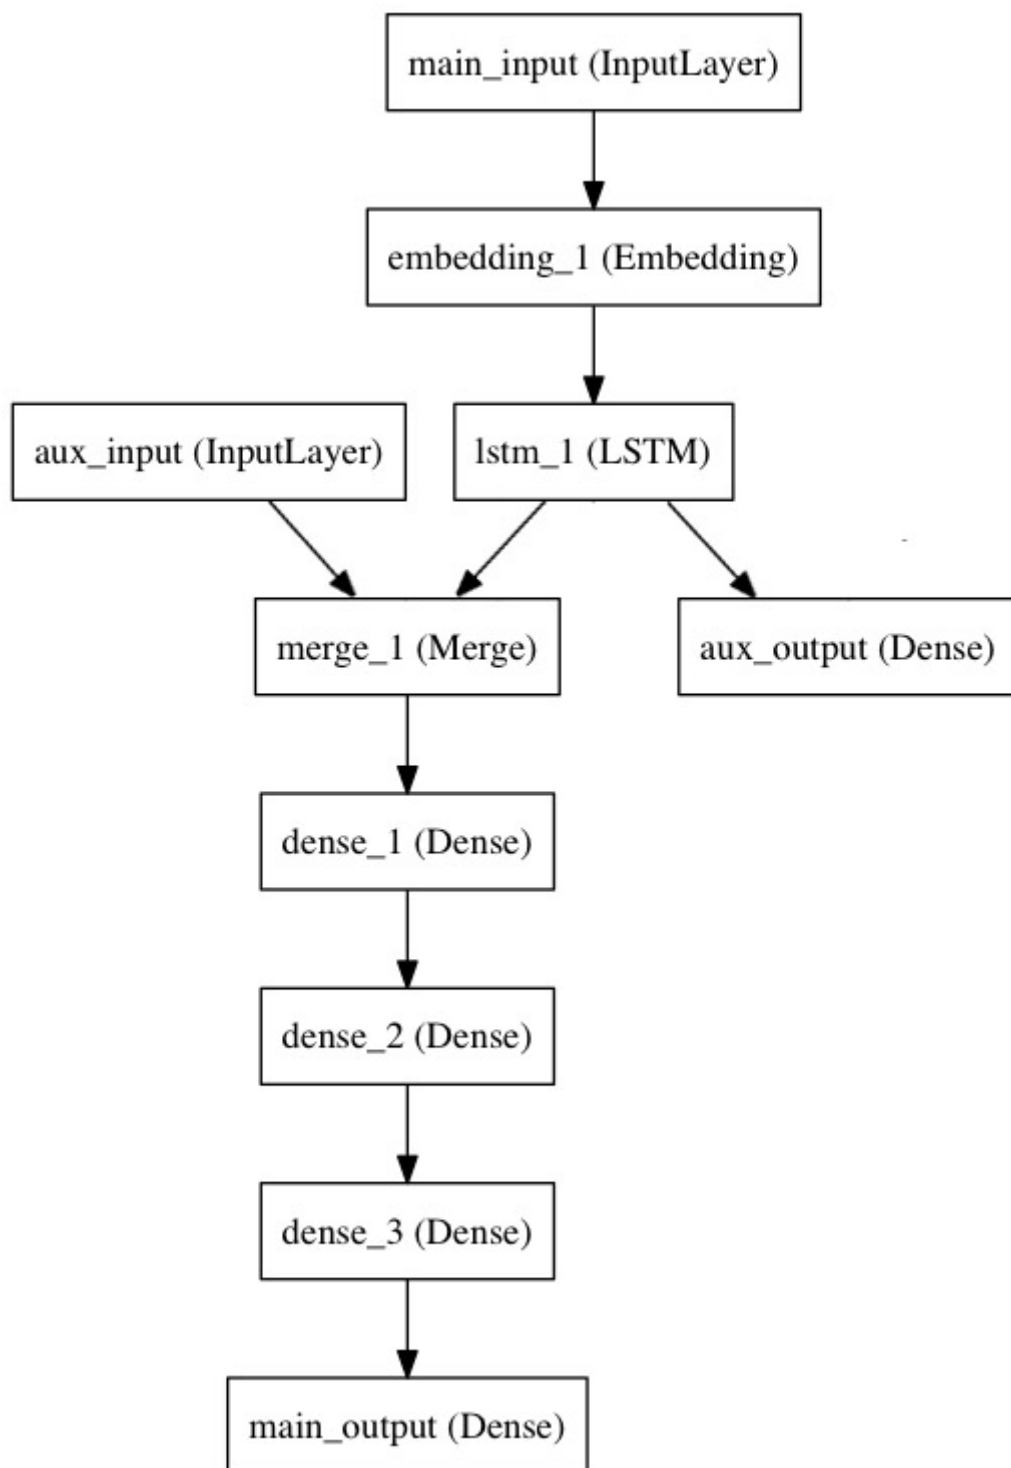
```
processed_sequences = TimeDistributed(model)(input_sequences)
```

Модели с несколькими входами и несколькими выходами

Рассмотрим хороший пример использования функционального API: модель с несколькими входами и несколькими выходами. Функциональный API позволяет легко управлять большим количеством пересекающихся потоков данных.

Давайте рассмотрим следующую модель. Мы попробуем предсказать сколько ретвитов и лайков будут получать заголовки новостей в Twitter. Основным входом в модель будет сам заголовок в виде последовательности слов. Помимо этого, наша модель будет иметь вспомогательный вход, на который будут подаваться дополнительные данные, такие как время публикации заголовка и т.п. Модель будет также иметь две функции ошибки. Использование основной функции ошибки ранее в модели является хорошим механизмом регуляризации для глубоких моделей.

Вот как выглядит наша модель:



Давайте реализуем это с помощью функционального API.

Основной вход получит заголовок в виде последовательности целых чисел (каждое целое число кодирует слово). Целые числа будут в интервале от 1 до 10000 (словарь из 10 тыс. слов), а последовательности будут длиной 100 слов.

```
from keras.layers import Input, Embedding, LSTM, Dense
```

```
from keras.models import Model
```

```
import numpy as np
```

`np.random.seed(0) # Зададим случайное число для генератора`

Вход заголовка: предназначен для получения последовательности

из 100 чисел в диапазоне от 1 до 10000

Обратите внимание, что мы можем дать имя любому слою,

#указав его в параметре name

`main_input = Input(shape=(100,), dtype='int32', name='main_input')`

Слой Embedding будет кодировать входную последовательность

#в последовательность 512-мерных векторов

`x = Embedding(output_dim=512, input_dim=10000, input_length=100)(main_input)`

LSTM преобразует векторную последовательность в один вектор,

содержащий информацию обо всей последовательности

`lstm_out = LSTM(32)(x)`

Здесь мы добавим вспомогательные ошибки, что позволит плавно обучать LSTM и Embedding-слой, даже если ошибки основной модели будут намного выше.

`auxiliary_output = Dense(1, activation='sigmoid', name='aux_output')(lstm_out)`

На этом шаге мы вводим в модель дополнительные данные, объединяя их с выходом LSTM:

`auxiliary_input = Input(shape=(5,), name='aux_input')`

`x = keras.layers.concatenate([lstm_out, auxiliary_input])`

Вначале располагаем полносвязную сеть из 3 Dense-слоев

`x = Dense(64, activation='relu')(x)`

`x = Dense(64, activation='relu')(x)`

`x = Dense(64, activation='relu')(x)`

И в завершении добавляем основной слой логистической регрессии

```
main_output = Dense(1, activation='sigmoid', name='main_output')(x)
```

Определяем модель с двумя входами и двумя выходами:

```
model = Model(inputs=[main_input, auxiliary_input], outputs=[main_output,
auxiliary_output])
```

Компилируем нашу модель и присваиваем вес 0.2 для значения вспомогательной ошибки. Для того чтобы указать разные `loss_weights` или `loss` для отдельного выхода, вы можете использовать список или словарь значений. Здесь мы передаем значение `loss` в качестве аргумента ошибки, поэтому одна и та же ошибка будет использоваться на всех выходах.

```
model.compile(optimizer='rmsprop',

              loss={'main_output': 'binary_crossentropy', 'aux_output': 'binary_crossentropy'},

              loss_weights={'main_output': 1., 'aux_output': 0.2})
```

Обучаем модель

```
model.fit({'main_input': headline_data, 'aux_input': additional_data},

        {'main_output': headline_labels, 'aux_output': additional_labels},

        epochs=50, batch_size=32)
```

Для вывода используйте:

```
model.predict({'main_input': headline_data, 'aux_input': additional_data})
```

или:

```
pred = model.predict([headline_data, additional_data])
```

Общие слои

Другое хорошее применение для функционального API — это модели, использующие общие слои. Давайте рассмотрим общие слои.

Рассмотрим набор данных твитов. Мы хотим построить модель, которая сможет определить, являются ли два твита от одного и того же человека или нет (это может позволить нам сравнить пользователей по сходству их твитов, например).

Одним из способов достижения этого является построение модели, которая кодирует два твита в два вектора, соединяет векторы, а затем добавляет логистическую регрессию; это выводит вероятность того, что два твита принадлежат одному и тому же автору. Затем модель будет обучена работе с положительными и отрицательными парами твитов.

Поскольку проблема симметрична, механизм кодирования первого твита следует использовать повторно (веса и все) для кодирования второго твита. Здесь мы используем общий LSTM слой для кодирования твитов.

Давайте построим это с помощью функционального API. Возьмем за вход для твита двоичную матрицу формы (280, 256), т.е. последовательность из 280 векторов размера 256, где каждое измерение в 256-мерном векторе кодирует наличие/отсутствие символа (из алфавита, состоящего из 256 частых символов).

```
import keras
from keras.layers import Input, LSTM, Dense
from keras.models import Model
```

```
tweet_a = Input(shape=(280, 256))
```

```
tweet_b = Input(shape=(280, 256))
```

Для совместного использования слоя с разными входными сигналами просто выполните однократную инициализацию слоя, а затем вызовите его на любое количество входных сигналов:

```
# Этот слой может принять за вход матрицу # и вернет вектор размера 64
```

```
shared_lstm = LSTM(64)
```

```
# Когда мы повторно используем один и тот же экземпляр слоя # несколько раз,
вес слоя # также повторно используется # (это фактически *один и тот же* слой).
```

```
encoded_a = shared_lstm(tweet_a)
```

```
encoded_b = shared_lstm(tweet_b)
```

```
# Затем мы сможем соединить два вектора. #
```

```
merged_vector = keras.layers.concatenate([encoded_a, encoded_b], axis=-1)
```

#И добавить логистическую регрессию сверху.

```
predictions = Dense(1, activation='sigmoid')(merged_vector)
```

#Мы определяем обучаемую модель,связывающую входы tweet#с предсказаниями.

```
model = Model(inputs=[tweet_a, tweet_b], outputs=predictions)
```

```
model.compile(optimizer='rmsprop',
```

```
    loss='binary_crossentropy',
```

```
    metrics=['accuracy'])
```

```
model.fit([data_a, data_b], labels, epochs=10)
```

Давайте сделаем паузу, чтобы посмотреть, как читать выходную или выходную форму общего слоя.

Понятие «узел слоя»

При каждом вызове слоя на каком-либо входе создается новый тензор (выход слоя) и добавляется «узел» к слою, связывая входной тензор с выходным тензором. При многократном вызове одного и того же слоя этому слою принадлежат несколько узлов с индексами 0, 1, 2...

В предыдущих версиях Keras можно было получить выходной тензор экземпляра слоя с помощью `layer.get_output()` или его выходную форму с помощью `layer.output_shape`. И все же можно (за исключением того, что функция `get_output()` была заменена на выходное свойство). Но что делать, если слой подключен к нескольким входам?

Пока слой подключен только к одному входу, путаницы нет, и `.output` вернет один выход слоя:

```
a = Input(shape=(280, 256))
```

```
lstm = LSTM(32)
```



```
encoded_a = lstm(a)
```

```
assert lstm.output == encoded_a
```

Not so if the layer has multiple inputs:

```
a = Input(shape=(280, 256))
```

```
b = Input(shape=(280, 256))
```

```
lstm = LSTM(32)
```

```
encoded_a = lstm(a)
```

```
encoded_b = lstm(b)
```

```
lstm.output
```

```
>> AttributeError: Layer lstm_1 has multiple inbound nodes,
```

hence the notion of «layer output» is ill-defined.

Use `get_output_at(node_index)` instead.

Ну ладно. Следующее:

```
assert lstm.get_output_at(0) == encoded_a  
assert lstm.get_output_at(1) == encoded_b
```

Достаточно просто, да?

То же самое справедливо и для свойств `input_shape` и `output_shape`: до тех пор, пока у слоя есть только один узел или пока все узлы имеют одну и ту же форму входа/выхода, тогда понятие «форма выхода/входа слоя» четко определено, и одна форма будет возвращена `lstm.output_shape/layer.input_shape`. Но если, например, применить один и тот же слой `Conv2D` к входу формы (32, 32, 3), а затем к входу формы (64, 64, 3), то слой будет иметь несколько форм входа/выхода, и нужно будет получить их, указав индекс узла, к которому они принадлежат:

```
a = Input(shape=(32, 32, 3))
```

```
b = Input(shape=(64, 64, 3))
```

```
conv = Conv2D(16, (3, 3), padding='same')
```

```
convded_a = conv(a)
```

#Пока только один вход, далее:

```
assert conv.input_shape == (None, 32, 32, 3)
```

convded_b = conv(b) #теперь свойство `input_shape` не сработает, но сработает следующее:

```
assert conv.get_input_shape_at(0) == (None, 32, 32, 3)assert conv.get_input_shape_at(1) == (None, 64, 64, 3)
```

Другие примеры

Примеры кода все еще являются лучшим способом начать, так что вот еще несколько.

Начальный модуль

Для получения дополнительной информации об архитектуре Inception смотрите раздел Изучаем сверточные модели глубже.

```
from keras.layers import Conv2D, MaxPooling2D, Input
```

```
input_img = Input(shape=(256, 256, 3))
```

```
tower_1 = Conv2D(64, (1, 1), padding='same', activation='relu')(input_img)
```

```
tower_1 = Conv2D(64, (3, 3), padding='same', activation='relu')(tower_1)
```

```
tower_2 = Conv2D(64, (1, 1), padding='same', activation='relu')(input_img)
```

```
tower_2 = Conv2D(64, (5, 5), padding='same', activation='relu')(tower_2)
```

```
tower_3 = MaxPooling2D((3, 3), strides=(1, 1), padding='same')(input_img)
```

```
tower_3 = Conv2D(64, (1, 1), padding='same', activation='relu')(tower_3)
```

```
output = keras.layers.concatenate([tower_1, tower_2, tower_3], axis=1)
```

Остаточное соединение на сверточном слое

Дополнительные сведения об остаточных сетях см. в разделе Глубокое обучение остаточных сетей для распознавания изображений..

```
from keras.layers import Conv2D, Input
```

```
#входной тензор для 3-канального изображения 256×256
```

```
x = Input(shape=(256, 256, 3))# 3×3 conv с 3 выходными каналами (так же, как и входные каналы)
```

```
y = Conv2D(3, (3, 3), padding='same')(x)#возвращает x + y.
```

```
z = keras.layers.add([x, y])
```

Модель общего видения

Эта модель использует один и тот же модуль обработки изображений на двух входах, чтобы классифицировать, являются ли две цифры MNIST одной и той же или разными цифрами.

```
from keras.layers import Conv2D, MaxPooling2D, Input, Dense, Flatten
from keras.models import Model
```

```
# Сначала определите модули видения
```

```
digit_input = Input(shape=(28, 28, 1))
```

```
x = Conv2D(64, (3, 3))(digit_input)
```

```
x = Conv2D(64, (3, 3))(x)
```

```
x = MaxPooling2D((2, 2))(x)
```

```
out = Flatten()(x)
```

```
vision_model = Model(digit_input, out)
```

```
# Тогда определите модель tell-digits-apart.
```

```

digit_a = Input(shape=(27, 27, 1))

digit_b = Input(shape=(27, 27, 1))

# Модель видения будет общей, веса и все все остальное.

out_a = vision_model(digit_a)

out_b = vision_model(digit_b)

concatenated = keras.layers.concatenate([out_a, out_b])

out = Dense(1, activation='sigmoid')(concatenated)

classification_model = Model([digit_a, digit_b], out)

```

Визуальная модель ответа на вопрос

Эта модель может выбрать правильный ответ из одного слова, когда задается естественный вопрос о картине.

Она работает, кодируя вопрос в вектор, кодируя изображение в вектор, объединяя их, и обучая сверху логистической регрессии по некоторому словарю потенциальных ответов.

```

from keras.layers import Conv2D, MaxPooling2D, Flatten
from keras.layers import Input, LSTM, Embedding, Dense
from keras.models import Model, Sequential

# Сначала определим модель видения, используя Sequential model. # Эта модель
будет кодировать изображение в вектор.

vision_model = Sequential()

vision_model.add(Conv2D(64, (3, 3), activation='relu', padding='same', input_shape=
(224, 224, 3)))

vision_model.add(Conv2D(64, (3, 3), activation='relu'))

vision_model.add(MaxPooling2D((2, 2)))

vision_model.add(Conv2D(128, (3, 3), activation='relu', padding='same'))

vision_model.add(Conv2D(128, (3, 3), activation='relu'))

```

```
vision_model.add(MaxPooling2D((2, 2)))
```

```
vision_model.add(Conv2D(256, (3, 3), activation='relu', padding='same'))
```

```
vision_model.add(Conv2D(256, (3, 3), activation='relu'))
```

```
vision_model.add(Conv2D(256, (3, 3), activation='relu'))
```

```
vision_model.add(MaxPooling2D((2, 2)))
```

```
vision_model.add(Flatten())
```

Теперь давайте возьмем тензор с выходом нашей модели видения:

```
image_input = Input(shape=(224, 224, 3))
```

```
encoded_image = vision_model(image_input)
```

*# Далее определим языковую модель для кодирования вопроса в вектор. #
Каждый вопрос будет длиной не более 100 слов, # и будем индексировать слова
как целые числа от 1 до 9999.*

```
question_input = Input(shape=(100,), dtype='int32')
```

```
embedded_question = Embedding(input_dim=10000, output_dim=256,  
input_length=100)(question_input)
```

```
encoded_question = LSTM(256)(embedded_question)
```

Соединим вектор вопроса и вектор изображения:

```
merged = keras.layers.concatenate([encoded_question, encoded_image])
```

*# И давайте тренировать логистическую регрессию более чем на 1000 слов
сверху:*

```
output = Dense(1000, activation='softmax')(merged)
```

Это наша последняя модель:

```
vqa_model = Model(inputs=[image_input, question_input], outputs=output)
```

Следующим этапом будет обучение этой модели фактическим данным.

Видео модель ответа на вопрос

Теперь, когда мы обучили нашу модель контроля качества изображения, мы можем быстро превратить ее в модель контроля качества видео. При соответствующем тренинге вы сможете показать ему короткое видео (например, 100-кадровое человеческое действие) и задать естественный вопрос на языке видео (например, «в какой вид спорта играет мальчик?» -> «футбол»).

```
from keras.layers import TimeDistributed
```

```
video_input = Input(shape=(100, 224, 224, 3))# Это наше видео, закодированное с помощью ранее обученной модели vision_model (веса повторно используются).
```

```
encoded_frame_sequence = TimeDistributed(vision_model)(video_input) # на выходе будет последовательность векторов
```

```
encoded_video = LSTM(256)(encoded_frame_sequence) # на выходе будет векторный
```

```
# Это представление кодировщика вопросов на уровне модели с повторным использованием тех же весов, что и раньше:
```

```
question_encoder = Model(inputs=question_input, outputs=encoded_question)
```

```
# Давайте используем его для кодирования вопроса:
```

```
video_question_input = Input(shape=(100,), dtype='int32')
```

```
encoded_video_question = question_encoder(video_question_input)
```

```
# И это наша видео-модель, отвечающая на вопросы:
```

```
merged = keras.layers.concatenate([encoded_video, encoded_video_question])
```

```
output = Dense(1000, activation='softmax')(merged)
```

```
video_qa_model = Model(inputs=[video_input, video_question_input], outputs=output)
```

